

SC-NBV: 面向 Unseen-Class HAR 的语义条件下一最佳视角选择

VPOCLIP_plus - Codex 代码修改与训练简版说明

核心目标: 不要让 PPO 记住 seen class 的“视角偏好”，而是学习一个可泛化的视角效用函数：根据当前视觉证据、语义信念、相机位姿和候选移动，预测该移动能带来的识别增益。第一阶段先做监督式 Next-Best-View (NBV) 排序；只有在多步连续移动时再接入 RL。

A. 问题定义与核心设计

- 重新定义任务:** 学习 $Q(\text{current evidence, semantic belief, pose, candidate action}) \rightarrow \text{expected recognition gain}$ ，而不是直接学习 policy $\pi(a|state)$ 。
- 当前视觉表示:** 从现有 HAR backbone 提取当前视角特征 z_t （建议保留一条 frozen/generalizable feature 分支，避免 seen-only fine-tuning 使 policy 过拟合）。
- 文本原型:** 对每个动作的 global_description 使用冻结 CLIP text encoder 得到文本原型 T_c ；现有 VPOCLIP_plus 可直接复用这部分。
- Semantic Belief:** 由当前视觉与所有动作文本原型的相似度得到 $p(c|o_t)$ ，再计算连续语义向量 $e_t = \sum p_c T_c$ 。不要把 argmax 类别 ID 喂给 policy。
- Top-K Semantic Belief:** 只保留 Top-K（建议 $K=5$ ）候选类别，重新归一化概率后求加权文本向量，减少低概率类别噪声。
- 不确定度:** 计算归一化熵 $u_t = H(p)/\log(C)$ ，作为独立输入；模型应学习“低不确定度少移动，高不确定度寻找补充视角”。
- 相机几何:** 用连续几何量描述当前相机位姿和候选移动，例如 $[\sin \text{azimuth}, \cos \text{azimuth}, \sin \text{elevation}, \cos \text{elevation}, \text{distance}]$ 与 $[\Delta \text{azimuth}, \Delta \text{elevation}, \Delta \text{distance}]$ ，不要只使用 one-hot。
- 候选动作:** 每个候选视角/移动分别计算 Q 值，最终选择 $\arg\max_a Q(s,a)$ 。可加入 STOP，若所有移动效用 ≤ 0 则不移动。
$$a^* = \arg\max_a Q\theta(z_t, e_t, \text{pose}_t, \text{action}_a, \text{uncertainty}_t)$$

B. 网络结构（第一版保持简单）

- Visual branch:** $z_t: 512 \rightarrow \text{MLP} \rightarrow 256$ 。尽量使用具备 unseen 泛化能力的 frozen/weakly-tuned feature；HAR 分类分支可继续使用你现有的融合特征。
- Semantic branch:** $e_t: 512 \rightarrow \text{MLP} \rightarrow 256$ 。再加入 visual-semantic interaction，例如 $z_{\text{proj}} \odot e_{\text{proj}}$ 。
- Geometry branch:** $[\text{current pose, candidate movement}] \rightarrow \text{小型 MLP} \rightarrow 32 \sim 64 \text{ 维}$ 。
- Utility head:** 拼接 visual、semantic、 $\text{visual} \odot \text{semantic}$ 、geometry、uncertainty 后通过 2~3 层 MLP 输出一个 scalar Q 。第一版无需 Transformer。

```
current video -> HAR encoder -> z_t -----\
                p(class|o_t) -> CLIP text -> e_t --+--> Utility MLP -> Q(s,a)
camera pose + candidate action -> Geometry MLP -----/
uncertainty -----/
for each candidate a: compute Q(s,a); select argmax
```

- 部署约束:** Q 网络不能看到未来候选视角图像。测试时只允许输入当前 observation + 当前 pose + 候选运动参数；future-view feature 只能用于训练监督。

C. 离线多视角数据如何自动生成训练标签

14. 利用 privileged multi-view data: 训练阶段已有同步多视角数据，因此对一个当前视角 v_i ，可以把其余视角 v_j 全部当作候选 action，离线计算每个候选的真实效用 $U(i \rightarrow j)$ 。

15. 效用应使用边际贡献: 不要评估候选视角单独有多好，而要评估它加入当前 observation 后提升了多少： $U = \text{Score}(\text{current} + \text{candidate}) - \text{Score}(\text{current})$ 。这样能直接优化互补视角，而不是冗余 canonical view。

16. 避免只用 Accuracy: 0/1 accuracy 太稀疏。优先使用 GT margin improvement: $M = s_y - \max_{c \neq y} s_{c_c}$, $U_margin = M_after - M_before$ 。即使预测仍错误，也能感知 GT rank 明显上升。

17. 组合效用: 可选最终标签: $U = \alpha \Delta\text{Margin} + \beta \Delta\text{Loss} + \gamma \text{Diversity} - \lambda \text{MotionCost}$ 。第一版建议先只用 ΔMargin ，稳定后再加入 diversity 与运动代价。

18. 训练样本展开: 若一个 clip 有 V 个同步视角，则每个 current view 可生成 $V-1$ 个 candidate 样本。数据项建议保存: current_id, current_feature, semantic_belief, pose, candidate_action, utility_label, class_id (class_id 仅做分析，不作为输入)。

D. Loss 与训练策略

19. 回归损失: 用 Huber(Q_pred, U_true) 比 MSE 更稳健。

20. 排序损失: 真正决策只关心候选排序，因此加入 pairwise ranking: 若 $U_i > U_j$ ，则要求 $Q_i > Q_j$ 。可用 margin ranking loss。

$$L = L_Huber + \lambda_rank L_rank \quad (\text{建议初始 } \lambda_rank = 0.5)$$

21. 不要泄漏 GT: 训练时 GT class 只允许用于生成 utility label，绝不能把 T_GT 或 GT class ID 输入 Q 网络。Semantic belief 必须和测试时一样由当前 observation 推断。

22. Semantic dropout: 为降低 seen-class shortcut，可对 semantic vector 做 10~20% dropout/zeroing 或轻微噪声；迫使模型同时依赖视觉和几何。

23. 先监督、后 RL: 如果任务目前主要是一跳移动 (view1 $\rightarrow$ move $\rightarrow$ view2)，优先把它当 contextual bandit/NBV ranking。只有扩展到连续 3~4 步移动、需要长期规划时，再用该 utility 网络初始化 PPO/SAC。

E. 评估与泛化验证

24. 必须做 pseudo-unseen: 把 seen classes 再拆成 policy-train 与 pseudo-unseen。所有架构、loss、超参都只在 pseudo-unseen 上选择，最后一次才评测真正 unseen，避免 policy 侧的数据泄漏。

25. 报告的不只是最终 HAR Accuracy: 同时报告 Fixed、Random-2、Farthest-view、Current PPO、SC-NBV、Oracle；并统计 oracle regret、Top-1/Top-3 oracle hit、平均 margin gain、action entropy、movement distance。最关键指标: $\text{Regret} = U_oracle - U_selected$ 。

F. Codex 实施优先级（建议直接按此顺序改代码）

阶段	Codex 要做的事
Phase 1 - 数据与标签	新增离线脚本，遍历同步多视角训练 clip；缓存 current feature、Top-K semantic belief、pose/action，并计算每个 candidate 的 Δ Margin utility。先验证 Oracle > Random 的 gap 与之前一致。
Phase 2 - 最小 SC-NBV	实现 SemanticConditionedViewUtilityNet: Visual MLP + Semantic MLP + Geometry MLP + interaction + scalar head。训练 Huber + ranking loss。
Phase 3 - 严格泛化	只在 seen-policy-train 训练；pseudo-unseen 选超参；true unseen 只做最终测试。检查 SC-NBV 是否稳定 > Random。
Phase 4 - 消融	去掉 semantic、去掉 uncertainty、去掉 interaction、仅 geometry、仅 visual、加入/去掉 diversity cost，明确提升来源。
Phase 5 - 多步扩展	如果单步 SC-NBV 已有效，再引入 history (GRU/Transformer) 与多步 RL；utility network 作为 critic/initialization，而不是从零训练 PPO。

G. 建议的数据接口 / 伪代码

```
# offline label generation
for clip in train_multiview:
    for current_view in views:
        z = encoder(current_view)
        p = clip_similarity(z, text_prototypes)
        e = topk_weighted_text_embedding(p, K=5)
        for candidate in other_views:
            score_before = margin(current_view, gt)
            score_after = margin(fuse(current_view, candidate), gt)
            U = score_after - score_before
            save(z, e, pose(current_view), action_to(candidate), entropy(p), U)

# training
Q = utility_net(z, e, pose, action, uncertainty)
loss = huber(Q, U) + 0.5 * ranking_loss(Q, U)

# inference
Q_all = [utility_net(state, a) for a in candidates]
a_star = argmax(Q_all) if max(Q_all) > 0 else STOP
```

H. Codex 修改时的硬性约束

- 不要修改现有 HAR 主干逻辑，先新增模块与离线数据脚本，保证可以随时切回原 baseline。
- 不要让 utility 网络读取 future-view image/feature；future view 仅用于离线生成 U。
- 不要把 GT label / GT text embedding 作为 policy 输入。
- 训练、验证、true-unseen 的 class split 要在日志中明确打印并保存到 checkpoint metadata。
- 每次实验固定 seed，并输出 Fixed / Random / SC-NBV / Oracle 的同一评测表。
- 先证明 supervised SC-NBV > Random，再考虑 PPO。若仍低于 Random，优先检查 feature 泛化、候选动作分布和 utility label，而不是继续调 RL 超参。

一句话研究定位

Active Open-Vocabulary Human Action Recognition through Semantic-Aware Next-Best-View Selection